

מבוא ללמידת מכונה – פרויקט מסכם

תאריך הגשה סופי: 17.7.26 בשעה 23:59

ברוכים הבאים למשרה החדשה שלכם כ-Data Scientists בחברת Nova Academy, חברה בינלאומית המספקת הכשרות טכנולוגיות מתקדמות לחברות וארגונים (B2B). העברת הכשרה שכזו היא עסק יקר הדורש היערכות מראש – החל מהקצאת סביבות ענן יקרות ועד להזמנת קייטרינג וערכות ציוד פיזיות. לאחרונה, ההנהלה מזהה כי אחוז גדול מההזמנות מבוטלות לפני תחילת הקורס (Dropped_Course). ביטולים אלה גורמים להפסדים כפולים – מצד אחד כסף שמתבזבז על תשתיות שהוכנו לשווא ומצד שני כיסאות ריקים בכיתה שמונעים מקבוצות נוספות להשתלב בשיעורים ומהחברה לקבל הכנסה נוספת. צוות ה-IT ייצא עבורכם נתונים היסטוריים מתוך מערכת ה-CRM של החברה הכוללים מידע רב על הזמנות העבר ומידע על ביטולן.

ההנהלה דורשת מכם לפתח מודל למידת מכונה שיקבל נתוני הרשמה חדשים וינבא את ההסתברות שהזמנה תבוטל. עליכם לבצע תהליך CRISP-DM מלא הכולל הבנה עסקית של ה-Domain אותו אתם חוזים, חקירה מעמיקה של סט הנתונים, ביצוע ניקוי של סט הנתונים, הנדסת מסבירים (Features) נוספים בהתאם לצורך, בניית מודל והגשת תוצאות חיזוי עבור ההזמנות הקיימות במערכת. מודל בעל רמת ביטחון ודיוק גבוהה ותובנות חזקות יאפשרו לצוות התפעול של החברה לבצע ניהול סיכונים חכם ולחסוך לחברה מיליוני דולרים.

טיב המודלים שלכם יימדד אל מול קובץ פתרונות שמור, **תוך שימוש במדד AUC**. הרף המינימלי **איתו נדרש לעבור הינו 0.70**. מעבר לדרישת המעבר של הרף המינימלי, יינתן ציון גם על טיב התוצאות אשר התקבלו עבור מודל החיזוי שבניתם, כאשר שלוש הקבוצות אשר יקבלו את ביצועי החיזוי הטובים ביותר על סט המבחן יקבלו בונוס של 5 נקודות למקום הראשון, 4 נקודות למקום השני ו-3 נקודות למקום השלישי (הבונוס יינתן עבור ציון הפרויקט).

לצורך ביצוע המשימה, מצורפים שני Datasets:

1. Train_Data.csv:

סט נתונים מציג את ההזמנות ההיסטוריות ומכיל את העמודות הבאות:

Client_ID – מזהה ייחודי לכל הזמנה.

Professionals_Count – מספר אנשי המקצוע המנוסים שרשומים בהזמנה.

Students_Count – מספר הסטודנטים שרשומים בהזמנה.

Observers_Count – מספר משקיפים (לא מבצעים תרגילים מעשיים בקורס אליו נרשמו) שרשומים בהזמנה.

Course_Start_Date – התאריך המיועד לפתיחת הקורס.

Practical_Hours – מספר שעות התרגול המעשי אשר מתוכננות בקורס.

Theory_Hours – מספר שעות הלמידה העיונית המתוכננות בקורס.

Registration_Days_Before – מספר הימים שעברו ממועד ההרשמה ועד ליום פתיחת הקורס.

Origin_Country – קוד המדינה ממנה מגיעה הקבוצה אשר ביצעה את ההזמנה.

Catering_Package – סוג חבילת ההסעדה שהוזמנה מראש בעבור הקבוצה.

Welcome_Gift_Type – סוג מתנת הפתיחה שחולקה לקבוצה.

Requested_Lab_Config – סביבת המעבדה שהקבוצה ביקשה לצורך הקורס (עמדת Linux / Mac וכו'...).

Assigned_Lab_Config – סביבת המעבדה שהוקצתה לקבוצה בפועל ביום הקורס עצמו.

Prev_Course_Dropouts – מספר הפעמים שהקבוצה ביטלה את הקורסים בעבר.

Prev_Course_Attended – מספר הפעמים שהקבוצה השתתפה בקורסים תחת החברה.

Pre_Course_Supports_Tickets – מספר הבקשות שהקבוצה ביקשה טרם תחילת הקורס.

Physical_Course_Kits – מספר ערכות הציוד הפיזיות אשר נדרש להכין מראש עבור הקבוצה.

Waiting_List_Days – מספר הימים שהקבוצה המתונה ברשימת ההמתנה עד לאישור פרטי ההרשמה במערכת.

Registration_Changes – מספר הפעמים שהקבוצה שינתה את פרטי ההזמנה שלה במערכת.

Enrollment_Type – אופן הרישום מול החברה.

Lanyard_Color – צבע שרוך התג אשר תענוד הקבוצה.

Client_Category – הסגמנט העסקי ממנו הקבוצה מגיעה (חברות Saas, Fintech וכו'...).

Submission_Source – ערוץ הרישום דרכו הגיעה ההזמנה.

Returning_Client – אינדיקטור בינארי הקבוע האם מדובר בלקוח חוזר (1) או חדש (0).

Agent_ID – מזהה ייחודי של סוכן או נציג המכירות שסגר את ההרשמה.

Company_ID – מזהה החברה שדרכה נרשמה הקבוצה.

Payment_Terms – תנאי התשלום שהוגדרו עבור ההזמנה.

Daily_Tuition_Cost – עלות ההדרכה היומית עבור אותה ההזמנה.

Dropped_Course – משתנה המטרה (Label). מציג האם הקבוצה ביטלה את ההשתתפות (1) או לא (0).

:Test_Data_No_Target.csv.2

סט נתונים המכיל את אותן העמודות המופיעות ב-Train_Data.csv למעט עמודת ה-Label אותה אתם נדרשים לחזות (Dropped_Course).

חלק א' – EDA והשלמת ערכים חסרים

בחלק זה עליכם להציג ניתוח אקספלורטורי מלא של הנתונים. מטרת שלב זה היא להבין את סט הנתונים לעומק, לזהות תקלות ודפוסים מעניינים ולבנות בסיס חזק לקראת שלב ה-Feature Engineering ובניית המודלים. הניתוח המינימלי יכלול ניתוחים סיכומיים של סט הנתונים, זיהוי קורלציות בין עמודות שונות ובין עמודת המטרה, ניתוחים סטטיסטיים עבור כל משתנה וויזואליזציה עבור המשתנים השונים.

בחלק זה נדרש להציג כמה שיותר ויזואליזציות מענייניות המאפשרות להציג מסקנות עבור הנתונים. מומלץ להשתמש במגוון גרפים ותרשימים שונים לצורך הצגת הנתונים. נדרש להסביר עבור כל ויזואליזציה אשר הצגתם לאורך העבודה מה היא מציגה לנו ומה ניתן ללמוד ממנה.

לאחר מכן, עליכם לבצע השלמת חוסרים על פי הנתונים והמסקנות אליהם הגעתם בשלב ה-EDA. השלמת החוסרים צריכה להיות מנומקת היטב ובעלת היגיון ברור עבור ההחלטות השונות אשר קיבלתם. במקרים בהם השלמת החוסרים משפיעה באופן ברור על התפלגות הנתונים באותה העמודה מומלץ להציג ויזואליזציה המראה את התפלגות הנתונים בעמודה לפני ואחרי השלמת החוסרים, במיוחד כאשר הוויזואליזציה ממחישה את ההיגיון שעל פיו פעלתם.

חלק ב' – Feature Engineering ו-Outlier Analysis

בחלק זה תידרשו לשפר את סט הנתונים כך שיוכל להפיק תוצאות טובות ומדויקות בשלב בניית המודלים. השתמשו במסקנות משלב ה-EDA אותו ביצעתם ומחקר של ה-Domain לצורך ביצוע פעולות Feature Engineering ו-Outlier Analysis בהתאם לצורך. בפרט, עבור כל מסביר חדש שיצרתם יש להסביר את הלוגיקה העומדת מאחוריו וכיצד עתיד לסייע למודל במשימת החיזוי. במקרים של התבססות על עקרונות מתמטיים מסוימים, יש לפרט את העיקרון המתמטי המתבססים עליו באמצעות נוסחה והסבר קצר.

שימו לב כי בשלב זה עליכם להתמודד גם עם "קללת המימדיות". עליכם להבין כיצד ניתן להוריד את מימד הבעיה באמצעות שיטות מבוססות מודלים / EDA.

בשלב ה-Outlier Analysis מומלץ להציג ויזואליזציות מתאימה על מנת שתספק גיבוי להחלטה עבור ה-Outliers ונימוק מלא מדוע קיבלתם את החלטה זו עבור אותו הנתון.

חלק ג' – תהליך אימון מודלים ו-Hyperparameters Tuning

בחלק זה מטרתכם להגיע למודל טוב ככל הניתן. עליכם לבנות 3 מודלים שונים לפחות, כאשר עבור כל מודל עליכם להסביר בקצרה על המודל ועל היפר הפרמטרים של המודל. מומלץ שאחד המודלים יהיה ממשפחת ה-XGBOOST, שכן ידוע כמודל המביא לתוצאות טובות בסט נתונים טבלאי.

עבור כל מודל עליכם לעשות Hyperparameters Tuning, כלומר לנסות ולהתאים את הפרמטרים של המודל כך שיביא לתוצאות הטובות ביותר. שימו לב כי תוצאות טובות בסט הנתונים $\neq$ תוצאות טובות בסט המבחן. הקפידו על Bias Variance Tradeoff והימנעו ממצב של Overfitting. באפשרותכם להוסיף רגולריזציה בהתאם למודל בו אתם עובדים (הוספת פונקציית קנס, קיטום עומק העץ וכו'...). יש לספק נימוק של תהליך בניית המודל ושל ההחלטות השונות אשר התקבלו והרציונל העומד מאחוריהן.

חלק ד' – Model Evaluation וניתוח התוצאות

לאחר בניית המודלים בחלק ג', בחלק זה תידרשו להעריך את טיב הביצועים של המודלים באמצעות Confusion Matrix ובאמצעות המדדים השונים המתבססים עליה. עליכם לפרט בקצרה על משמעות כל מדד בהקשר לשאלת החיזוי בה אתם פועלים ובמה כל מודל מצליח יותר או פחות. ניתן לערוך השוואה בין ביצועי המודלים השונים.

לאחר ביצוע ה-Model Evaluation, עליכם לבחור מודל אחד מהמודלים אשר בניתם ולנתח את התוצאות שהתקבלו במודל באופן יותר מעמיק. נסו להבין כיצד המודל שבחרתם מתמודד עם התצפיות השונות. לדוגמא: האם יש תצפיות מסוימות בהן המודל מספק חיזוי ברמת ביטחון נמוכה יותר? לצורך שלב זה, נדרש להשתמש במודל SHAP אשר נלמד במסגרת הקורס על מנת להגיע למסקנות עבור המסבירים החשובים ואופן קבלת ההחלטות של המודל מאחורי הקלעים.

חלק ה' – סיכום

בחלק זה תידרשו להציג תקציר מנהלים של העבודה (**עד עמוד לכל היותר**). נדרש לפרט בקצרה את התהליך שביצעתם, גילויים מרכזיים שנעשו לאורך התהליך, נקודות חשובות שאתם מעוניינים להדגיש, מסקנות ודרכים נוספות לשיפור יכולת החיזוי של המודל במידה ולא יושמו בתהליך החיזוי הנוכחי.

קבצי ההגשה

עליכם להגיש שלושה קבצים במסגרת הפרויקט:

1. קובץ פלט: קובץ זה נדרש להיות בפורמט CSV ולהכיל שתי עמודות, כאשר העמודה הראשונה תיקרא Client_ID והעמודה השנייה תיקרא Drop_Probability. מטרת הקובץ הינה להציג את תחזיות המודל עבור כל תצפית. כל שורה תציג Client_ID אשר נמצא בקובץ Test_Data_No_Target.csv ואת **ההסתברות** שהמודל נותן (ולא חיזוי "קשה" של 0 או 1) לביטול ההשתתפות של הקבוצה. שם הקובץ צריך להיות Group_XX_Submission.csv, כאשר XX מייצג את מספר הקבוצה. לדוגמה, שם הקובץ של קבוצה 1 יהיה Group_01_Submission.csv. להלן דוגמה לקובץ זה:

Drop_Probability	Client_ID
0.45774832	62246
0.10221539	43031
0.99805343	26571
0.72571185	77694
0.20942985	22185
0.35561964	54569
0.78605343	64162

2. מחברת Jupyter: קובץ זה נדרש להציג את כל הקוד אשר כתבתם לצורך ביצוע הפרויקט. על המחברת להציג את כלל הויזואליזציות, הסברים על כל ויזואליזציה, תיעוד מלא של הקוד והסברים על החלטות והשלבים השונים לאורך הפרויקט. שימו לב כי בסופה של העבודה עליכם לבצע את ה-Pipeline גם על סט המבחן (Test_Set_No_Target.csv), ועל כן חשוב לוודא כי המחברת מציגה תיעוד מלא ומפורט של התהליך אשר נעשה ושל הפרמטרים, השיטות והמודל אותם החלטתם לבחור בסופן של כל הניסיונות. **יש להקפיד על מחברת מסודרת על ידי שימוש בכותרות, בלוקים של טקסט, נוסחאות מתמטיות וכו' ...** על המחברת להיות מוגשת בפורמט ipynb בשם Group_XX_Notebook.ipynb. יש לציין בראש מחברת הקוד את מספר הקבוצה ואת שמות המגשים + תעודות הזהות של המגשים.
3. דו"ח מסכם: בקובץ זה עליכם להציג את תהליך ה-CRISP-DM שביצעתם במילים. על הדו"ח לכלול את כל החלטות שקיבלתם לאורך התהליך, מדוע קיבלתם אותן, לאילו מסקנות הגעתם ועוד... מטרת הדו"ח היא לסכם במספר עמודים את כל הפירוט המופיע במחברת ה-Jupyter. **אורך הדוח המקסימלי עד 10 עמודים לכל היותר.** על הדוח להיות בגופן David בגודל 12, רווח 1.5 שורות, שוליים "רגילים" (Normal). שימוש בנספחים כגון ויזואליזציות (כאשר המלל והמסקנות נכללים בדו"ח ולא בנספחים וקיימת הפנייה מסודרת לנספח הרלוונטי) / ביבליוגרפיה לא ייחשבו במספר העמודים של הדו"ח.
- על הדוח להיות מוגש בפורמט PDF בשם Group_XX_Report.pdf. יש לציין בראש הדו"ח את מספר הקבוצה ואת שמות המגשים + תעודות הזהות של המגשים. הדו"ח ישמש לבחינת העבודה כאשר מחברת ה-Jupyter תשמש לאימות השלבים אותם פירטתם בדו"ח ולצורך התעמקות בחלקים מסוימים אשר ציינתם בדו"ח. יש להפעיל שיקול דעת בהחלטות בהן מעוניינים להתעמק בדוח.
- את שלושת הקבצים יש להגיש כקובץ ZIP יחיד. שם הקובץ יהיה בפורמט Group_XX.zip. את הקובץ יש להעלות למערכת ה-Moodle עד תאריך ההגשה המצוין בראש קובץ ההנחיות. **הגשה אשר חורגת מפורמט ההגשה תגרור הורדה אוטומטית של 5 נקודות מציון הפרויקט.**

הערות:

1. לאורך כל שלבי הפרויקט ניתן (ומומלץ) להשתמש בכלים / שיטות שלא נלמדו לאורך הקורס. הפרויקט הזה מהווה הזדמנות להתנסות לראשונה בעולמות ה-Data Science ולכן כדאי לקרוא וללמוד דרכים נוספות לביצוע שלבים מסוימים בתהליך ה-CRISP-DM.
2. אחת מהמטרות המרכזיות של המעבדות היא לסייע לכם בתהליך ביצוע הפרויקט. **מומלץ מאוד להגיע ולעבוד על הפרויקט בשעות המעבדה, לשאול שאלות ולהתייעץ.** זאת ההזדמנות שלכם להתנסות ולליישם את החומר התיאורטי אשר נלמד בהרצאות ובשיעורי התרגול.
3. ההנחיות המוצגות בדרישות הפרויקט הן **דרישות מינימליות** עבור ביצוע הפרויקט. ניתן ואף מומלץ להעמיק בשלבים השונים ולנסות להגיע למסקנות מענייניות עבור סט הנתונים. פרויקטים אשר ישתמשו בכלים שלא נלמדו כחלק מחומרי הקורס ויבצעו עבודה מעמיקה ומורכבת מעבר לדרישות יקבלו בonus לציון הפרויקט (גובה הbonus ייקבע על פי מגוון הכלים השונים בהם ישתמשו הסטודנטים ועומק הניתוח).
4. במידה ואתם מסתמכים על מאמרים בספרות המקצועית / אתרים מסוימים יש להוסיף הערת שוליים / הפנייה כלשהי עם ציטוט וקישור למקור המידע המתאים.

הציון על הפרויקט יינתן על פי המדדים הבאים:

חלק בפרויקט	משקל מהציון	הערות
חלק א' – EDA והשלמת ערכים חסרים	25%	
חלק ב' – Feature Engineering ו-Outlier Analysis	20%	
חלק ג' – תהליך אימון מודלים ו-Hyperparameters Tuning	20%	
חלק ד' – Model Evaluation וניתוח התוצאות	15%	
חלק ה' – סיכום	5%	
סדר ובהירות	10%	יש להקפיד על בהירות הצגה, הסדר והפירוט של החלקים השונים בדו"ח הסופי ובמחברת הקוד בפרט.
טיב התוצאות של מודל החיזוי	5%	יתבצע על פי דירוג <u>יחסי</u> של כלל ההגשות על פי מדד AUC של סט המבחן.

שימו לב! הציון יינתן בהתאם לעומק הניתוח, ההסברים והכלים בהם השתמשתם בכל שלב. מטרת הפרויקט היא לחקור ולהעמיק בסט הנתונים בדומה לפרויקט מחקר בתעשייה. מענה מלא אך רדוד על סעיפי הפרויקט לא יספיק לקבלת ניקוד מלא.

בהצלחה!